

Pokročilá experimentální roadmapa pro analýzu odolnosti protokolu WebTunnel v prostředí strukturálně podobného legitimního provozu

1. Kritická dekonstrukce modelu hrozeb a matematická formulace úskalí detekce

Hodnocení odolnosti kryptografických protokolů a nástrojů pro obcházení cenzury vyžaduje striktní vymezení schopností útočníka a naprosté pochopení limitů analytických metod. Tradiční přístupy k detekci síťových anomálií a klasifikaci šifrovaného provozu v akademickém prostředí často spoléhají na nerealistické předpoklady ohledně výpočetní kapacity cenzora, což vede k vývoji modelů s přehnaně optimistickou úspěšností. Následující text definuje nezbytné inženýrské a matematické základy, které musí být v rámci výzkumných aktivit na Katedře informatiky PřF JU absolutně dodrženy pro dosažení vědecké průkaznosti experimentů zabývajících se protokolem Tor WebTunnel¹.

Reálný cenzor, operující na úrovni poskytovatele internetového připojení (ISP) formou takzvaného in-path pasivního či aktivního odposlechu, čelí obrovskému objemu dat protékajícím gigabitovými až terabitovými linkami. Z tohoto důvodu je aplikace komplexních modelů hlubokého učení (Deep Learning) na každý jednotlivý paket celého síťového toku výpočetně neúnosná a zavádí nepřipustnou latenci do sítě. Opatření cenzora se primárně omezují na nákladově efektivní techniky hloubkové inspekce paketů (Deep Packet Inspection, DPI)². Z hlediska detekce kryptograficky maskovaných protokolů, mezi které WebTunnel patří, se analýza rozpadá do tří základních fází. První fáze zahrnuje extrakci metadat z úvodního vyjednávání spojení, typicky z hlaviček TLS ClientHello, kde cenzor využívá otisky jako JA3 či JA4 a analyzuje pole Server Name Indication (SNI)¹.

Pokud úvodní fáze neposkytne jednoznačný výsledek, cenzor přistupuje k analýze metadat post-handshake toku. Jedná se o směrové statistiky paketů, jejich velikosti a časy mezi jejich příchody (inter-arrival times). Aby cenzor dokázal zablokovat spojení dříve, než dojde k přenosu podstatného objemu cenzurovaných informací, omezuje se takzvaná Early-Flow klasifikace pouze na prvních několik desítek paketů². Inspekce syrových fragmentů užitečného zatížení (Payload Slicing) je u plně šifrovaných protokolů (Fully Encrypted Protocols, FEP) teoreticky neúčinná z důvodu absence rozeznatelných aplikačních hlaviček v šifrovaném bloku².

Realistický model hrozeb pro WebTunnel tedy předpokládá útočníka, který na základě směrových posloupností prvních datových rámců aplikuje klasifikátor schopný pracovat v reálném čase, aniž by způsobil kolaterální škody na obrovském množství legitimních asynchronních spojení (např. WebSockets či gRPC).

1.1 Úniky dat a paměťový efekt syntetických laboratorních artefaktů

Největší hrozbou pro validitu modelů strojového učení trénovaných na síťových datech je fenomén zavádějících korelací (spurious correlations) neboli únik dat (Data Leakage). Klasifikátor se v izolovaném laboratorním prostředí nenaučí detekovat skutečnou komunikační sémantiku protokolu WebTunnel, ale místo toho se dokonale přizpůsobí specifickým hardwarovým či softwarovým artefaktům testovací sítě¹. Pokud model dosáhne vysoké přesnosti díky těmto artefaktům, v reálném nasazení (Open-World setting) jeho výkon fatálně selže.

Identifikovaný artefakt	Zdroj úniku informací v testovacím prostředí	Nutná sanitační metoda
Identifikátory síťových uzlů	IP adresy, MAC adresy, zdrojové a cílové porty specifikující konkrétní uzly laboratorní topologie (např. Nginx proxy na portu 443 a Tor bridge na portu 15000) ¹ .	Úplné odstranění L2 (Ethernet) a L3 (IP) hlaviček. Z L4 (TCP/UDP) vrstvy musí být extrahovány pouze payloady nebo délky hlaviček, adresní prostor je nutné vynulovat ⁴ .
Velikost maximální přenosové jednotky (MTU)	Pokud legitimní provoz pochází z reálných sítí (např. 1492 bajtů přes PPPoE) a WebTunnel z Dockeru (1500 bajtů), model klasifikuje primárně fragmentaci na linkové vrstvě ¹ .	Normalizace délek paketů oříznutím (truncation) nad limit MTU a odstranění paketů generovaných specificky procesem fragmentace.
TCP Stack OS Fingerprinting	Rozdíly ve výchozích velikostech TCP oken (Window Scaling), výchozích hodnotách Time to Live (TTL) nebo algoritmech pro kontrolu zahlcení mezi Linuxem a Windows ¹ .	Striktní odstranění celých TCP hlaviček včetně pole Options, které obsahuje specifické identifikátory operačního systému a SACK (Selective Acknowledgment) mapy.
Absence síťového jitteru (Network Pacing)	V izolovaném virtuálním prostředí Docker/KVM probíhá komunikace prakticky okamžitě, RTT (Round Trip Time) je	Zavedení nedeterminismu a zpoždění na úrovni softwarového směrovače pomocí nástrojů pro emulaci reálných podmínek,

	konstantní a limitně se blíží nule ¹ .	zajištění variabilního zpoždění (jitter).
--	---	---

Eliminace těchto faktorů vyžaduje implementaci přísného předzpracování, v němž jsou síťové toky zbaveny veškerých informací nesouvisejících se samotným komunikačním vzorcem.

1.2 Matematická dekonstrukce klamu základního poměru

Klam základního poměru (Base Rate Fallacy) je fundamentálním problémem ovlivňujícím efektivitu systémů pro detekci obcházení cenzury v reálném světě. Dosavadní studie detekce obvykle prezentují výkonnost systémů s pomocí metriky ROC-AUC (Area Under the Receiver Operating Characteristic Curve) na vyvážených souborech dat. V reálné síťové infrastruktuře je

však podíl toků tvořících spojení přes systémy jako Tor WebTunnel (označme jako base rate α) vůči veškerému legitimnímu provozu extrémně nízký¹. Moderní výzkum zavádí notaci parametru λ , který představuje poměr počtu legitimních toků ku jednomu toku obcházejícímu cenzuru⁶.

Například hodnota $\lambda = 1$ značí vyvážený mix, $\lambda = 100$ znamená přibližně jednaprocentní

výskyt, zatímco reálné hodnoty v pátečních sítích mohou dosahovat $\lambda = 10^4$ až $\lambda = 10^6$ ⁶.

Nechť je definována senzitivita klasifikátoru (True Positive Rate, TPR), tedy pravděpodobnost úspěšné detekce WebTunnelu, a míra falešných poplachů (False Positive Rate, FPR), tedy pravděpodobnost, že legitimní provoz je chybně označen za WebTunnel. Podle Bayesovy věty je pravděpodobnost, že spojení označené klasifikátorem skutečně představuje WebTunnel (tzv. Precision), definována následovně:

$$P(\text{WebTunnel} \mid \text{Alarm}) = \frac{TPR \cdot \alpha}{TPR \cdot \alpha + FPR \cdot (1 - \alpha)}$$

Vynikající klasifikátor trénovaný v laboratoři může dosahovat přesnosti blízké se 99 % s mírou

$FPR = 0.01$. Pokud je tento model nasazen na síti s realistickým základním poměrem

$\alpha = 10^{-4}$ (tedy $\lambda = 9999$), výsledná preciznost dramaticky klesá:

$$P(\text{WebTunnel} \mid \text{Alarm}) = \frac{0.99 \cdot 10^{-4}}{0.99 \cdot 10^{-4} + 0.01 \cdot (1 - 10^{-4})} \approx 0.0098$$

Z tohoto matematického důkazu vyplývá, že v takto nastaveném prostředí představuje více než 99 % všech vyvolaných poplachů falešná pozitiva, což vede k obrovským kolaterálním škodám (False Discovery Rate přesahuje 99 %). Poskytovatel připojení by při nasazení takového modelu zablokoval obrovské množství legitimního obsahu, což činí klasifikátor nepoužitelným⁵.

Současný stav vědeckého poznání ukazuje, že ani sofistikované hluboké neuronové sítě aplikované izolovaně na jednotlivé síťové toky neškálují na takto extrémní nevyváženost.

Preciznost state-of-the-art algoritmů klesá k nule ve chvíli, kdy hodnota λ překročí hranici

10000⁶.

Z výše uvedeného plyne bezpodmínečný požadavek, aby byl návrh experimentů koncipován primárně k optimalizaci metriky Precision při fixovaných a extrémně nízkých mírách falešných

poplachů, konkrétně $FPR \leq 10^{-4}$ nebo $FPR = 10^{-5}$ ¹.

2. Architektura experimentálního testbedu a blueprint generování provozu

Dosažení robustnosti výzkumu v oblasti odhalování a obcházení cenzury je podmíněno vytvořením izolovaného, plně kontrolovatelného a zároveň realistického simulačního prostředí. Katedra informatiky musí při implementaci klást důraz na precizní modelování topologie sítě využívající kontejnerizaci a softwarově definované sítě, aby se zabránilo křížové kontaminaci lokálních artefaktů.

2.1 Koncepte odděleného testbedu pomocí Linux Namespaces a KVM

Platforma pro sběr dat musí být rozdělena do tří logických domén: Klientská zóna, Zóna útočníka (cenzora) a Serverová zóna¹. Pro tuto segregaci je optimální využití nativních Linuxových síťových jmenných prostorů (Linux Network Namespaces), případně Docker kontejnerů propojených výhradně prostřednictvím virtuálního přepínače Open vSwitch. Klientská zóna se skládá z velkého množství nezávislých kontejnerů, které spouštějí automatizované skripty (využívající nástroje jako Selenium, Puppeteer nebo generátory zátěže) produkující jak žádoucí (legitimní), tak nežádoucí (WebTunnel) požadavky. Veškerý provoz z klientské zóny musí být směřován přes jediný centrální uzel představující Zónu útočníka. V tomto uzlu probíhá zachytávání datových toků do formátu PCAP a současně se zde provádí modifikace paketů pro simulaci fyzických vlastností sítě. Teprve odtud je provoz směřován do Serverové zóny, kde běží reálné implementace cílových služeb i WebTunnel proxy. Umístění bodu odposlechu (Packet Capture) uvnitř Zóny útočníka je kritické pro získání pohledu, který plně odpovídá perspektivě skutečného in-path cenzora¹.

2.2 Zřízení infrastruktury Tor WebTunnel

Protokol WebTunnel představuje pokročilý "pluggable transport" vyvinutý pro síť Tor, který zapouzdřuje (encapsuluje) komunikaci do spojení nápadně připomínajícího standardní WebSocket protokoly. Jádro WebTunnelu je architektonicky odvozeno od dřívějšího protokolu HTTPT, jehož cílem bylo učinit provoz rezistentním vůči aktivnímu sondování (Active Probing) ze strany cenzorů¹. Cenzor při pokusu o připojení k serveru neobdrží podezřelou chybovou zprávu, nýbrž validní webový obsah legitimního charakteru.

Implementace WebTunnel infrastruktury na serverové straně vyžaduje integraci několika vrstev. Prvním prvkem je reverzní proxy server, v praxi obvykle Nginx, nakonfigurovaný pro obsluhu běžné webové domény s platným TLS certifikátem (například certifikátem podepsaným autoritou Let's Encrypt pomocí protokolu ACME)¹¹. Tato proxy komunikuje přímo s internetem a naslouchá na standardním portu 443. Zásadním konfiguračním prvkem je definice takzvané tajné cesty (Secret Path) – unikátního pseudonáhodného URL řetězce o délce minimálně 24 znaků¹¹. Pokud příchozí HTTPS požadavek směřuje na standardní cesty (např. /index.html), Nginx jej zpracuje a vrátí neškodný obsah. Pakliže však požadavek směřuje na definovanou

tajnou cestu a obsahuje hlavičky pro Upgrade na protokol WebSocket (nebo zachovává HTTPPT sémantiku), proxy server jej interně přepošle (proxy_pass) na backend, kde naslouchá lokální proces Tor bridge (např. na smyčce 127.0.0.1 a portu 15000)¹¹.

Na straně klientské zóny je nutné nakonfigurovat Tor proces s integrovaným WebTunnel transportním pluginem tak, aby směřoval na správnou doménu a využíval odpovídající tajnou cestu. Pro vygenerování reprezentativních vzorků provozu je nezbytné, aby klientské automaty simulovaly reálné chování uživatelů, včetně asymetrického stahování objemných souborů (bulk download) i interaktivního procházení s různě dlouhými přestávkami na čtení.

2.3 Generování strukturálně podobného legitimního provozu (Hard Negatives)

Hlavní výzvou při analýze cenzury není odlišení šifrovaného provozu od nešifrovaného, ale schopnost diferencovat WebTunnel od ostatních, strukturálně identických šifrovaných toků. Vzhledem k tomu, že WebTunnel parazituje na sémantice protokolu HTTPS a HTTPPT¹, musí být pro vytvoření spolehlivého modelu umělé inteligence nasbírána masivní soubor takzvaných "Hard Negatives" (těžkých negativ). Tyto toky na vrstvě L4 sdílejí s WebTunnelem většinu statistických charakteristik.

Typ provozu (Hard Negatives)	Charakteristika a podobnost s WebTunnel	Generační nástroje pro testbed
Dlouhožijící WebSocket (WS/WSS)	Stejně jako WebTunnel udržuje stabilní, trvalé, obousměrné TLS spojení, jímž proudí asynchronní zprávy ¹ . Vyznačuje se nepravidelnými bursty a nízkou latencí, typické pro finanční tickery nebo chat ¹² .	Nasazení lokálních WebSocket serverů a klientů naprogramovaných v Node.js/Python simulujících real-time messaging nebo burzovní data.
HTTP/2 a gRPC multiplexing	Umožňuje přenos mnoha nezávislých proudů v rámci jediného TCP spojení, což vytváří dlouhodobé relace plné zhuštěných datových shluků s komplexním stavovým automatem ¹ .	Integrace gRPC služeb a HTTP/2 multiplexorů zprostředkovávajících neustálý polling.
Moderní QUIC / HTTP/3 relace	Ačkoli QUIC operuje na UDP, hloubkové inspekční mechanismy jej analyzují na úrovni toků nezávisle na	Nástroje jako aioquic nebo implementace v jazyce Go generující paralelní datové toky (QUIC streams) a

	transportní vrstvě ¹ . Poskytuje silný šum s vlastnostmi rychlého ustavení spojení.	testující generalizaci modelu ¹ .
Video streaming a RTC aplikace	Služby využívající adaptivní bitovou rychlost (DASH/HLS přes HTTPS) nebo WebRTC (zabezpečené komunikace nad SRTP/DTLS) ¹ . Vykazují trvalý asymetrický přesun dat.	Automatizované instance webových prohlížečů stahující segmentované video či lokálně hostované WebRTC klienty.

Zajištění vysokého objemu těchto specifických legitimních relací je nutným předpokladem k tomu, aby klasifikátor neoznačoval každé dlouhé a zašifrované TCP spojení za cenzurovaný provoz.

2.4 Zavedení realismu pomocí Network Emulatoru (tc-netem)

Zásadním rizikem každého laboratorního uspořádání je absolutní absence nedeterminismu, na který modely hlubokého učení trpí extrémní senzitivitou. Aby se zabránilo přeučení na specifické časy odezvy sítě (RTT), vnáší se v rámci Zóny útočnicka syntetický šum prostřednictvím linuxového subsystému Traffic Control, modulu netem¹.

Vložením přesně kalibrovaného zpoždění a rozptylu (jitter) se emulují reálné vzdálenosti mezi uzly v internetu. Konfigurace umožňuje definovat distribuci tohoto zpoždění tak, aby odpovídala reálným výkyvům, například pomocí normálního rozdělení s korelací vůči předchozím paketům. Mimo zpoždění musí netem aplikovat i řízenou ztrátovost paketů (Packet Loss). Záměrné zahazování určitého zlomku promile až procenta paketů donutí obě komunikující strany aktivovat mechanismy na transportní vrstvě – konkrétně procedury jako Fast Retransmit a Timeout (RTO) v rámci TCP spojení. Toto chování následně modifikuje pole oken, sekvenci i dynamiku potvrzování (ACK), čímž model analyzující časové mezery získá dostatečně heterogenní a zašuměná vstupní data, odolná proti zapamatování ideálních laboratorních vzorců. Do testbedu se taktéž začleňuje pravděpodobnostní duplikace a změna pořadí paketů (Reordering) na úrovni rozhraní¹.

3. Standardy předzpracování dat a pipeline pro extrakci příznaků

Surové záznamy datových toků ve formátu PCAP představují vysokodimenzionální nestrukturovaná data, která nelze přímo použít pro konvenční ani hluboké učení. Enormní variabilita délek spojení a přítomnost informací napomáhajících k nechtěnému úniku štitků (Label Leakage) činí z fáze předzpracování kritický inženýrský úkol¹. Návrh pipeline se opírá o nástroje pro analýzu síťových vrstev, primárně knihovny typu pyshark (odvozenina od Tsharku) či dpkt pro vysoce výkonnou iteraci na úrovni C¹.

3.1 Srovnávací analýza reprezentací síťového provozu

V moderní literatuře věnované analýze šifrovaného provozu jsou zastoupeny tři fundamentálně odlišné přístupy k reprezentaci jednoho datového spojení, přičemž každá z metod nabízí kompromis mezi sémantickou přesností a výpočetní složitostí:

1. **Sériová posloupnost paketů (Sequence-based Representation):** Tento formát považuje síťový tok, definovaný pětici hodnot (zdrojová IP, cílová IP, zdrojový port, cílový port, protokol), za sekvenční strukturu v čase. Pro každý zachycený paket je zaznamenána jeho délka, přičemž je obohacena o informaci o směru (např. kladné hodnoty pro pakety zaslané klientem, jako je $+1500$, a záporné pro pakety přijaté od serveru, například -54)¹. K velikostem je připojen vektor časování, neboli inter-arrival časy zaznamenávající hodnotu Δt vůči bezprostředně předcházejícímu rámci. Sériová reprezentace skvěle vystihuje dynamiku komunikace a sekvence aplikačních interakcí, nicméně naráží na nutnost zarovnávání kratších relací nulovým paddingem (Zero Padding) k dosažení fixního rozměru vstupního tenzoru⁴.
2. **Makroskopické agregáty relace (Flow-level Statistical Aggregates):** Přístup zaměřený na globální charakteristiky celého spojení. Ze surových paketových posloupností jsou extrahovány distribuce a parametry odvozené od obou směrů přenosu¹. Mezi zkoumané metriky patří průměr, medián, rozptyl velikostí, percentilové distribuce a specifické indikátory typu poměru počtu paketů obou směrů. Důležitou podmnožinou jsou statistiky o takzvaných dávkách (bursts) – skupinách paketů odeslaných tímtež směrem bez přerušení paketem v opačném směru. Tato metoda je ideální pro rychlou, klasickou analýzu využívající tabulková data s jasně vymezenými vektory vlastností.
3. **Surové bajtové posloupnosti raných fází spojení (Early Raw Bytes):** Nejméně abstraktní metoda, která přímo načítá prvních N bajtů z payloadu aplikací transportní vrstvy, nebo z prvních K hlaviček¹. V kontextu plně šifrované komunikace typu FEP se tyto bajty zdají jako náhodný kryptografický šum, ovšem výzkum demonstruje schopnost pokročilých modelů (např. v architektuře TrafficFormer nebo Deep Packet) objevovat drobné asymetrie v raných fázích výměny, včetně částí vyjednávání šifer, ačkoliv za cenu masivních výpočetních nároků¹⁴.

3.2 Postup striktní sanitační protokolu

Pro transformaci do výše zmíněných reprezentací se aplikuje rigidní čistící a normalizační vrstva (Sanitization Protocol), bez níž modely degradují na detektory laboratorních artefaktů¹:

Krok 1 zahrnuje absolutní eliminaci Ethernetových rámců. MAC adresy a jakékoliv hlavičky fyzického charakteru odrážející specifikace lokální laboratoře jsou ireverzibilně zahozeny. Krok 2 přistupuje k IP vrstvě, kde musí být bez výjimky vynulovány veškeré IP adresy zúčastněných stran a vymazány ukazatele o délce cesty jako je TTL¹. V případě nesplnění tohoto bodu by si neuronová síť vytvořila přímé vazby mezi cílovou podsítí a klasifikací WebTunnelu, což vede k

selhání na jakékoli jiné IP adrese.

Krok 3 modifikuje transportní vrstvu (TCP/UDP), kde dochází k vynulování zdrojových a cílových portů a k pročištění pole TCP Options (obsahujícího SACK, Timestamp nebo informace o Window Scaling), které zprostředkovaně odhaluje implementaci operačního systému kontejnerů¹. Krok 4 nahrazuje absolutní časové pečeti paketu v celkovém toku relativními intervaly mezidobí od předchozí události, čímž zajišťuje odolnost vůči dlouhodobým změnám síťové propustnosti¹. Poslední proces normalizace směrování se provádí detekcí iniciálního SYN paketu, který vždy ustanovuje referenční směr klienta (kladné znaménko), načež jsou všechny toky odpovídajícím způsobem zrcadleny bez ohledu na bod, v němž byl odposlech PCAP nasazen.

3.3 Rozdělovací strategie Train/Val/Test Splitu

Závažným metodologickým prohřeškem v oblasti zpracování strojového učení je standardní stochastické rozdělení relací mezi tréninkové, validační a testovací datasety bez ohledu na vzájemnou provázanost dat, což vede ke křížové kontaminaci. Pro tento výzkum je vyžadována striktní izolace podpořená dvěma základními architekturami dělení¹:

Destination-Split (Cílově orientované rozdělení): Musí být zaručeno, že relace směrované na jeden konkrétní cílový server nebo IP (například proxy simulující WebTunnel chování na konkrétním clusteru, případně jeden konkrétní WebSocket server z produkčního seznamu Hard Negatives) nikdy nefigurují současně napříč fázemi trénování a testování. Pokud by model analyzoval návštěvnost domény example.com při tréninku, nesmí tuto doménu obdržet k evaluaci¹. Cílové stroje jsou proto rozčleněny deterministicky před zhotovením finálních datasetů.

Temporal/Session-Split (Časová asymetrie): Úlohou testovací vrstvy je simulovat nasazení detektoru v reálném čase do neznámé budoucí distribuce. Testovací množina musí výlučně

obsahovat data sesbíraná v časovém horizontu ($T + \Delta$), zatímco trénink probíhá na vzorcích z časového okna T ¹. Takový přístup prověřuje dlouhodobou stabilitu získávaných otisků.

4. Architektonické návrhy klasifikačních modelů a algoritmy

Na úrovni zpracování dat je úkolem implementovat vícerozměrnou analytickou rodinu klasifikátorů s odlišnými paradigmaty učení. Vývoj by měl zapouzdřit klasické přístupy založené na expertně budovaných charakteristikách stejně tak, jako adaptivní end-to-end architektury z rodiny hlubokých neuronových sítí¹.

4.1 Referenční Baseline na klasických statistikách (XGBoost)

Základní referenční bod tvoří tradiční potrubí pro strojové učení. Model na bázi XGBoost (eXtreme Gradient Boosting) nebo algoritmů typu Random Forest operuje výlučně nad ručně zpracovanými flow statistikami, jak byly definovány výše (např. trvání, burst metriky, distribuce Δt po percentilech)¹. Zásadní charakteristikou je rychlost úsudku z důvodu nízké algoritmické hloubky.

Optimalizace architektury zahrnuje konfiguraci hyperparametrů na omezování hloubky rozhodovacích stromů pro potlačení overfittingu na laboratorní fluktuace a povinnou modifikaci distribučních ztrát pomocí argumentu přidávajícího rozdílnou váhu pod-zastoupeným vzorkům, reflektující extrémní nevyváženost WebTunnel paketů vůči všudypřítomným WebSocket proudům.

4.2 Reprezentace jednorozměrnou konvolucí (1D-CNN pro Deep Packet analýzu)

Posun v oblasti analýzy bez nutnosti ručního feature engineeringu představují modely inspirované architekturou Deep Packet¹. Tento přístup nevyužívá dvourozměrné matice, avšak aplikuje konvoluční techniky nad signálem proměnlivé délky. Vstupním vektorem je sekvence paketových velikostí o stanovené maximální velikosti (například s nulovým paddingem do délky 1500 časových kroků) reprezentující vývoj komunikačního stavu¹.

Architektura 1D-CNN se typicky skládá ze série konvolučních operací (Conv1D) s posuvnými filtry s nevelkými rozměry jader. Cílem menších konvolučních jader (např. o velikosti 3 až 5) v kombinaci s narůstajícím počtem výstupních filtrů (64 následovaných 128 či 256) je hierarchická asimilace lokálních závislostí časování a fragmentace relací¹. Aby model odolal zapamatování konkrétních šumových otisků a zamezil vanishing gradient fenoménu, zařazuje se striktně Batch Normalizace jednorozměrných řad (BatchNorm1D) za každou aktivační vrstvu a prvek vypouštění spojení (Dropout) s pravděpodobností minimálně 0.4.

Rozhodující odlišností pro takto nevyvážený dataset musí být volba ztrátové funkce.

Minimalizace standardní křížové entropie (Cross-Entropy) při obrovském procentu snadno rozpoznatelného balastu směřuje model k nekompetenci odhalit marginálně zastoupený WebTunnel. Místo toho je nezbytná implementace tzv. **Focal Loss**¹. Focal Loss modifikuje

křížovou entropii přidáním modulátoru $(1 - p_t)^\gamma$, kde p_t je predikovaná pravděpodobnost

příslušné třídy a γ představuje zaostřovací parametr. Tato rovnice automaticky zanedbává snadno rozpoznatelné třídy a exponenciálně navyšuje gradientní postih v situaci, kdy model nedokáže diferencovat spletené struktury Hard Negatives objektů.

4.3 Baseline architektury rodiny Transformer (TrafficFormer)

Stav vědeckého poznání ukazuje enormní potenciál mechanismů sebe-pozornosti (Self-Attention) u modelů z rodiny Transformer, jež dosud dominovaly primárně úlohám zpracování textu (NLP)¹. Adaptace těchto sítí na analýzu protokolu (jako je TrafficFormer nebo FlowletFormer) vnímá sekvence síťových toků jako větné syntaxy s vlastní slovní zásobou¹⁷.

Transformerové modely na bázi TrafficFormer pracují přímo na konverzi syrových bajtů spojení. Systém typicky sdružuje bajty do dvojic (bigramů), čímž vytváří řetězce o formátu čtyřmístných hexadecimálních znaků. Na tento řetězec je aplikován tokenizační algoritmus Byte Pair Encoding (BPE), jenž sestavuje lexikon spojováním nejčastějších shluků do fixní velikosti tokenového korpusu, čímž vznikne abstraktní reprezentace šifrovaného toku¹⁷.

Kritickým aspektem nasazení Transformerů je takzvaná fáze pre-trainingu nad obrovským objemem neoznačených síťových dat bez asistence štítků. Tréninkové cykly zahrnují učební vzorce jako je Masked Burst Modeling (MBM). Při MBM je část (například 15 %) sekvenčních

tokenů z jednoho burstu náhodně nahrazena maskovací značkou. Samo-pozornostní obousměrná síť se pak z kontextu okolních bajtů napříč vrstvami snaží zrekonstruovat chybějící části, čímž získá hluboké porozumění sémantickým závislostem šifrované výměny, které překračují lidské analytické schopnosti¹⁷. Jako podpůrná komponenta figuruje pomocná úloha zvaná Same Origin-Direction-Flow (SODF), která pomáhá definovat korelaci směrů napříč různými relacemi, čímž se redukuje komplexita naučeného prostoru¹⁸. Výzkumná práce s WebTunnelem proto bude primárně využívat takto masivně předtrénovaný model z knihovny HuggingFace, z kterého pomocí procesu jemného ladění (Fine-Tuning) vyextrahuje hluboce strukturované vztahy směrem ke konkrétní cenzurované třídě.

5. Zkušební rámec, extrémní prahy detekce a profilování výpočetních nákladů

Ignorování metrik reálného operačního nasazení degraduje efektivitu mnoha studií analyzujících systémy pro obcházení cenzury na úroveň teoretických cvičení. Validace navržených klasifikátorů napříč všemi třemi kategoriemi musí procházet přes dedikovaný vyhodnocovací cyklus operující pod asymetrickými prahy a striktními požadavky na míru falešných pozitivních chyb (FPR).

5.1 Rámec evaluačních metrik pro cenzurní systémy

Běžně udávaná souhrnná přesnost (Accuracy) postrádá ve vysoce asymetrickém doménovém kontextu jakoukoliv diskriminační výpovědní hodnotu¹. Pokud tvoří WebTunnel 0.01 % vzorků a model zablokuje absolutně všechny, jeho čistá Accuracy bude stále impozantních 99.99 %, ačkoli jako detektor absolutně selhal. Základní posouzení tedy musí využívat asymetrickou Precision-Recall křivku (PR-AUC), která ilustruje obchod (trade-off) mezi citlivostí (schopností identifikovat skrytý provoz) a precizností¹.

Aby výzkum disponoval jednoznačnou interpretovatelností pro DPI subsystémy reálných telekomunikačních operátorů, je modelům nutné vnutit specifický bod rozhodovacího prahu. Precision musí být sledována exaktně při garantované maximální hranici falešných pozitiv chyb na úrovních $FPR = 10^{-3}$, 10^{-4} a případně i 10^{-5} ¹. Tato evaluace prověří, zda klasifikátor po tak dramatickém nárůstu konzervativity (kdy se vyvaruje označit téměř vše, co není absolutně transparentním profilem) zvládne udržet citlivost na mírách převyšujících hranici nahodilosti¹.

Kromě globálních čísel je nezbytná analýza konkrétních zmatení modelu prostřednictvím lokalizovaných Matrik Záměn (Confusion Matrices) izolovaně zaměřených pouze proti skupinám "Hard Negatives". Metodika musí exaktně formulovat míru mylného zablokování například pro streamovací protokoly v reálném čase versus míru falzifikace vůči dlouhodobým interaktivním skořápkám (shells)¹.

5.2 Testování odolnosti vůči zátěži Base Rate (FDR Projection)

Navazujícím krokem zkušebního procesu je zátěžové testování vůči proměnlivému parametru prevalence α , simulující různé stupně výskytu WebTunnelu na zkoumaném perimetru, a matematická projekce False Discovery Rate (FDR)¹. Z rovnice představené v první kapitole se

extrapolují hodnoty pro odlišné vrstvy nasazení:

- $\alpha \in 10^{-2}$ (výskyt v 1 % případů): Zastupuje nerealistické lokální sítě monitorované v rámci specifického sub-uzlu instituce, často užívané jako referenční odrazový můstek pro komparativní chápání.
- $\alpha \in 10^{-4}$ (výskyt 1 vůči 10 000): Relativně realistické nasazení odpovídající obranyschopným hraničním uzlům menších providerů (ISP), kde modely začínají vykazovat rapidní propad preciznosti (často až ke 3 %)⁶.
- $\alpha \in 10^{-6}$ (výskyt 1 vůči 1 milionu): Stav na obrovských národních backbonových liniích. Pokud testovaná 1D-CNN dosáhne experimentálního FPR v řádech jednotek z tisíce (10^{-3}), zátěžový test pro tyto linky poukáže na skutečnost, že více než 99.9 % ze všech hlášených podezření a případných restrikcí uvalených na toky reprezentuje falešný balast (False Discovery Rate přes 99.9 %) a cenzor odřízne zásadní kus národního provozu⁵.

Studie navrhuje pokročilou metodiku cenzury (viz práce od Jansena et al.) se vůči tomuto problému brání využitím takzvané host-based analýzy, která posiluje jistotu kumulací statistik napříč časem nad mnoha toky ke stejné cílové IP adrese nebo hostiteli. Tím se míra chyby exponenciálně marginalizuje k čisté nule (snížením limitních logaritmických požadavků na datový počet zkoumaných incidentů)². Implementace podobných agregačních postupů pro hostitelská zkoumání představuje důležitý sekundární nástroj k odhalení útočných struktur.

5.3 Profilování algoritmické a výpočetní ceny (Computational Baseline)

Rovnice modelu hrozeb definuje schopnost analyzovat spojení z řádu milisekund. Složitost modelů typu TrafficFormer nebo Transformerů využívajících samo-pozornost nad čtvercovými maticemi vztahů často vede k výpočetní katastrofě z hlediska rychlosti¹. Proto se ve zkušebním rámci musí pečlivě profilovat výpočetní latence (Model Inference Latency) uváděná jako čistý čas trvání usouzení jedné predikce nad jedním paketovým shlukem (v ms/flow) s ohledem na paměťovou režii¹. Taktéž je zkoumána celková propustnost DPI enginu z hlediska počtu toků (flows/sec), čímž se vyhodnocuje uplatnitelnost a hardwarové dimenzování klasifikátoru na hardwarových branách operátora.

6. Vyhodnocení strukturálních vad protokolu a modely doporučení

Získané experimentální poznatky následně povedou k přesné diagnostice zranitelných částí transportních protokolů rodiny WebTunnel/HTTPPT. Nalezení klíčových defektů umožní designování preventivních ochranných systémů.

6.1 Přirazení zranitelných znaků a de-maskování sémantiky

Pokud nasazené modely dosáhnou smysluplné separační schopnosti (při akceptovatelném nízkourovňovém FPR), musí být provedena introspekce vysoce vážených příznaků. U sémantiky WebTunnelu je hlavní předpokládanou slabinou absence jakýchkoli mechanismů pro tvarování

provozu (Traffic Shaping). Protokoly rodiny HTTPPT negenerují žádné umělé změny do charakteristik mezer (inter-packet timing) a nijak nemění přirozené vzorce shluků dat vytvořené procesy komunikujícími přes tunel¹³. Tím umožňují modelům DPI a Deep Learning klasifikátorům aplikovat otisky typické pro Tor navzdory ochrannému plášti v podobě HTTPS obálky¹³. Jádrem sítě Tor je koncipování dat do striktně daných obdélníkových struktur, buněk neboli "cells", o pevně stanovené velikosti 514 bajtů. Jedná-li se o pasivní encapsulaci do tunelu bez modifikace zarovnávání (cell packing patterns), propisují se shluky o objemech násobných této konstantě do transportní statistické vrstvy¹. Asymetrická povaha Tor prohlížení se tak nadále liší od typických, obousměrně vyrovnaných zpráv z burzovních API či chatovacích klientů v legitimních WebSockets, jelikož WebTunnel obsahuje propastné mezery způsobené sestupnými bursty při asynchronním načítání webového obsahu¹. Tyto rozdíly v distribuci shluků vytvářejí hlubokou statistickou trhlinu pro modely hlubokého učení.

6.2 Návrh protipatření a rezilientních vzorů pro nástroje Pluggable Transports

Rozbor musí vyústit v sadu rigorózních, technických doporučení adresovaných vývojářům systémů Pluggable Transports, směřujících ke ztížení klasifikace cenzorem na úroveň naprosté ztráty jistoty (pád preciznosti v zátěžovém prostředí)¹:

Základním kamenem evoluce musí být implementace adaptivních algoritmů na přidávání vaty (Padding). Nejedná se o náhodné doplňování konstantním objemem nul, nýbrž o kontextově-asertivní vyrovnávání hranic Tor buněk tak, aby byly rozbity 514bajtové shluky a zároveň se tak nestalo se zavedením prohibitivní režie na celkovou pásmovou šířku obou zúčastněných stran¹. Souběžně s doplňováním je důležitou komponentou aktivní modul pro dekompozici a štěpení paketů, obdoba prototypu Shaperd, který dokáže odesílat modifikované struktury libovolné sekvenční délky (Traffic Shaping of arbitrary lengths) na přesný povel, a efektivně tím maskovat vzorce odesílání plně šifrovaných kanálů, aniž by tím byla omezována celková doba vyřízení toku².

Dále se doporučuje adaptace principů z rodiny protokolů pro emulaci prioritizace (Stream Mimicry). Pokud WebTunnel předstírá existenci nad HTTP/2, je vhodné, aby samotný tunel vykazoval shodnou stromovou prioritizaci streamů a multiplexních oken, jakou implementují plnohodnotné klientské implementace těchto protokolů, čímž dojde k sjednocení vlastností na aplikační rovině analýzy hlubokých Transformer modelů¹.

Posledním doporučením, reagujícím na případné nasazení modelů využívajících agregaci dat na úrovni cílového hostitele (Host-based analysis), je vynucení rotace serverových instancí a sázka na efemerní proxy servery². Úspěšná obranná topologie WebTunnelu by v budoucnu měla integrovat přístupy, které zaručí časté střídání IP adres nebo sdílení propustností v duchu systémů Snowflake (respektive metod navrhovaných u systému Obscura), což systematicky naruší proces časové akumulace statistické významnosti na jednom stabilním cílovém bodě².

Citovaná díla

1. Zadávací protokol - Kouba Matěj Bc.pdf
2. On Precisely Detecting Censorship Circumvention in Real-World Networks -

ResearchGate,

https://www.researchgate.net/publication/378136873_On_Precisely_Detecting_Censorship_Circumvention_in_Real-World_Networks

3. Bytes to Schlep? Use a FEP: Hiding Protocol Metadata with Fully Encrypted Protocols - arXiv, <https://arxiv.org/html/2405.13310v2>
4. Pytorch Implementation of Deep Packet: A Novel Approach For Encrypted Traffic Classification Using Deep Learning | Mun Hou's Blog, <https://blog.munhou.com/2020/04/05/Pytorch-Implementation-of-Deep-Packet-A-Novel-Approach-For-Encrypted-Traffic-Classification-Using-Deep-Learning/>
5. On Precisely Detecting Censorship Circumvention in Real-World Networks - Rob Jansen, <https://www.robjansen.com/publications/precisedetect-ndss2024.pdf>
6. On Precisely Detecting Censorship Circumvention in Real-World Networks (NDSS 2024) · Issue #312 · net4people/bbs - GitHub, <https://github.com/net4people/bbs/issues/312>
7. NDSS Symposium 2024 Program, <https://www.ndss-symposium.org/ndss-program/symposium-2024/>
8. On Precisely Detecting Censorship Circumvention in Real-World Networks - NDSS Symposium, <https://www.ndss-symposium.org/wp-content/uploads/2024-394-slides.pdf>
9. HTTPT: A Probe-Resistant Proxy - USENIX, <https://www.usenix.org/conference/foci20/presentation/frolov>
10. Troll Patrol: Detecting Blocked Tor Bridges - University of Waterloo, <https://dspacemainprd01.lib.uwaterloo.ca/server/api/core/bitstreams/2825c095-3fbe-4b71-a8a7-2ae6b7e7eea8/content>
11. WebTunnel Bridge - Join the Tor Community, <https://community.torproject.org/relay/setup/webtunnel/>
12. PTPerf: On the performance evaluation of Tor Pluggable Transports - Bamsoftware, <https://www.bamsoftware.com/software/dnstt/2309.14856.pdf>
13. Huma: Censorship Circumvention via Web Protocol Tunneling with Deferred Traffic Replacement - University of Waterloo, <https://cs.uwaterloo.ca/~dbarrada/papers/kamali-ndss26.pdf>
14. TrafficFormer: An Efficient Pre-trained Model for Traffic Data | Request PDF - ResearchGate, https://www.researchgate.net/publication/392750930_TrafficFormer_An_Efficient_Pre-trained_Model_for_Traffic_Data
15. Deep Packet: A Novel Approach For Encrypted Traffic Classification Using Deep Learning, https://www.researchgate.net/publication/319622754_Deep_Packet_A_Novel_Approach_For_Encrypted_Traffic_Classification_Using_Deep_Learning
16. Deep Packet: A Novel Approach For Encrypted Traffic Classification Using Deep Learning, <https://www.scribd.com/document/445463118/Deep-Packet-A-Novel-Approach-For-Encrypted-Traffic-Classification-Using-Deep-Learning>
17. FlowletFormer: Network Behavioral Semantic Aware Pre-training Model for Traffic

- Classification - arXiv, <https://arxiv.org/html/2508.19924v1>
18. TrafficFormer: An Efficient Pre-trained Model for Traffic Data - IEEE Computer Society,
<https://www.computer.org/csdl/proceedings-article/sp/2025/223600a102/22K50xTq93y>
 19. PRE-TRAINING MODEL WITH FLOWLETS FOR TRAFFIC CLASSIFICATION - OpenReview, <https://openreview.net/pdf?id=PUm9OaFNvf>
 20. TrafficFormer: Efficient Traffic Data Model | PDF | Transmission Control Protocol - Scribd,
<https://www.scribd.com/document/906343231/TrafficFormer-an-Efficient-Pre-trained-Model-for-Traffic-Data>
 21. CNN-based deep learning reduces obfs4 false positive rate by an,
https://corpus.lantern.io/findings/2024-wails-precisely__cnn-improves-but-insufficient-at-scale/